ALERTA TEMPRANA DE DESERCIÓN ESTUDIANTIL

informe ejecutivo

Autor: Antonio Rubio

Fecha: 26 de octubre de 2026

ÍNDICE

ÍNDICE 2
Resumen ejecutivo 3
Descripción del problema 3
Descripción de la propuesta 3
Definición del problema 3
Objetivo 3
Descripción de los datos 4
Fuente de datos 4
Organización de las entidades 4
Variables principales 4
Conclusiones del análisis exploratorio 5
Preparación e ingeniería de variables 5
Metodología y esquema de validación 6
Modelado y evaluación 6
Algoritmos y métricas 6
Selección del modelo 7
Explicación del riesgo 7
Impacto en el negocio 8
Limitaciones 9
Consideraciones éticas y de privacidad 9
Conclusiones y recomendaciones 10

Resumen ejecutivo

Este proyecto se inicia con el objetivo de evitar la baja temprana de alumnos en las materias impartidas en la Open University.

Descripción del problema

Aproximadamente, el 31% de las inscripciones en cualquier materia termina en abandono, provocando pérdidas económicas para la universidad.

Se asume que el cuerpo de tutores tiene la capacidad para contactarse con el total de alumnos que se da de baja, pero, sin la información necesaria, no es eficaz realizar esa tarea contactando alumnos de manera aleatoria.

Descripción de la propuesta

Crear un modelo predictivo que ordene al listado de alumnos por nivel de riesgo de abandonar una determinada materia. De esta manera, el cuerpo de tutores puede desempeñar la tarea de retención de manera más eficiente.

Definición del problema

Open University es una universidad de Gran Bretaña orientada a clases a distancia. Cada materia dura 8/9 meses con tutores y tiene una alta tasa de deserción. Esto tiene un costo económico, pero también influye en el que ese alumno termine desertando la universidad completamente.

El análisis inicial muestra que, el 27% de las bajas ocurre antes del inicio de la cursada, 24% entre el inicio de la cursada y el día 30, y 49% después del día 30. Este proyecto se enfoca en el último grupo.

Público

La dirección académica, que define la capacidad y el presupuesto de tutoría, y los tutores, que usan la lista priorizada.

Hipótesis:

- H1: la caída de actividad en el campus virtual precede al abandono.
- H2: el desempeño en las primeras evaluaciones es la señal más fuerte.
- H3: una vez conocido el comportamiento, el perfil sociodemográfico aporta poco.

Restricciones: usar solo información disponible al día 30, no discriminar por atributos protegidos y respetar la capacidad limitada de los tutores.

Objetivo

Detectar al día 30 de cursada, al menos al 50% de alumnos que vayan a abandonar una materia.

Descripción de los datos

Fuente de datos

Se utilizó el *Open University Learning Analytics Dataset* liberado bajo licencia Creative Commons que permite usarlo citando a los autores (los datos se encuentran en el archivo README.md). Los datos están anonimizados. Cubren 32593 inscripciones, 7 materias, y 22 cursadas en cuatro períodos entre 2013 y 2014. Las cursadas indicadas con B comienzan en febrero y las indicadas con J arrancan en octubre.

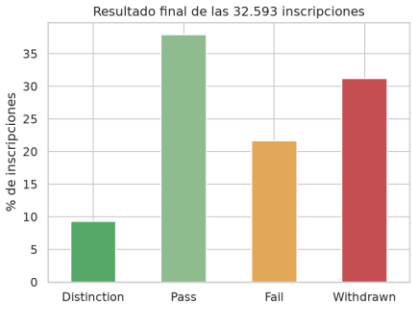
Organización de las entidades

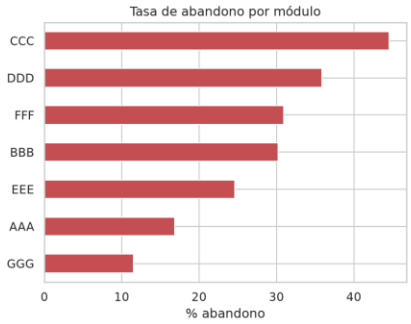
Entidad	Registros	Contenido
studentInfo	32.593	Perfil del estudiante y resultado final (variable objetivo)
studentRegistration	32.593	Fechas de inscripción y de baja
studentVle	10.655.280	Cantidad de clics diarios en cada recurso del campus virtual
studentAssessment	173.912	Entregas y notas
vle / assessments / courses	6.364 / 206 / 22	Catálogos de recursos, evaluaciones y cursadas

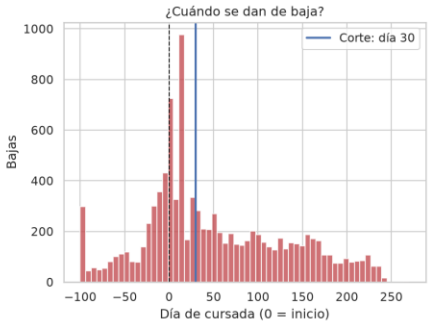
Variables principales

Variable	Descripción	Mediana: abandona	Mediana: no abandona
nota_media	Nota promedio de lo entregado (0–100)	70	79
clicks_total	Cantidad de clics en el campus virtual hasta el día 30	197	249
clicks_relativos	Clics / mediana de su cursada	0,77	1,06
clicks_ult_14d	Clics en los últimos 14 días	64	79
dias_activos	Días distintos con actividad	12	14
clicks_pre_inicio	Clics antes del inicio de la cursada	20	29
dias_sin_actividad	Días desde la última actividad	1	1
vencidas_no_entregadas	Evaluaciones vencidas sin entregar	0	0
tasa_entrega	Entregadas / vencidas (18% nulos: sin evaluaciones vencidas)	1,0	1,0
studied_credits	Créditos que cursa en simultáneo	60	60
dias_inscripcion_anticipada	Días entre la inscripción y el inicio	58	52
educacion_nivel	Nivel educativo previo (0–4)	2	2
imd_decil	Decil socioeconómico del barrio (3,7% nulos)	4	4

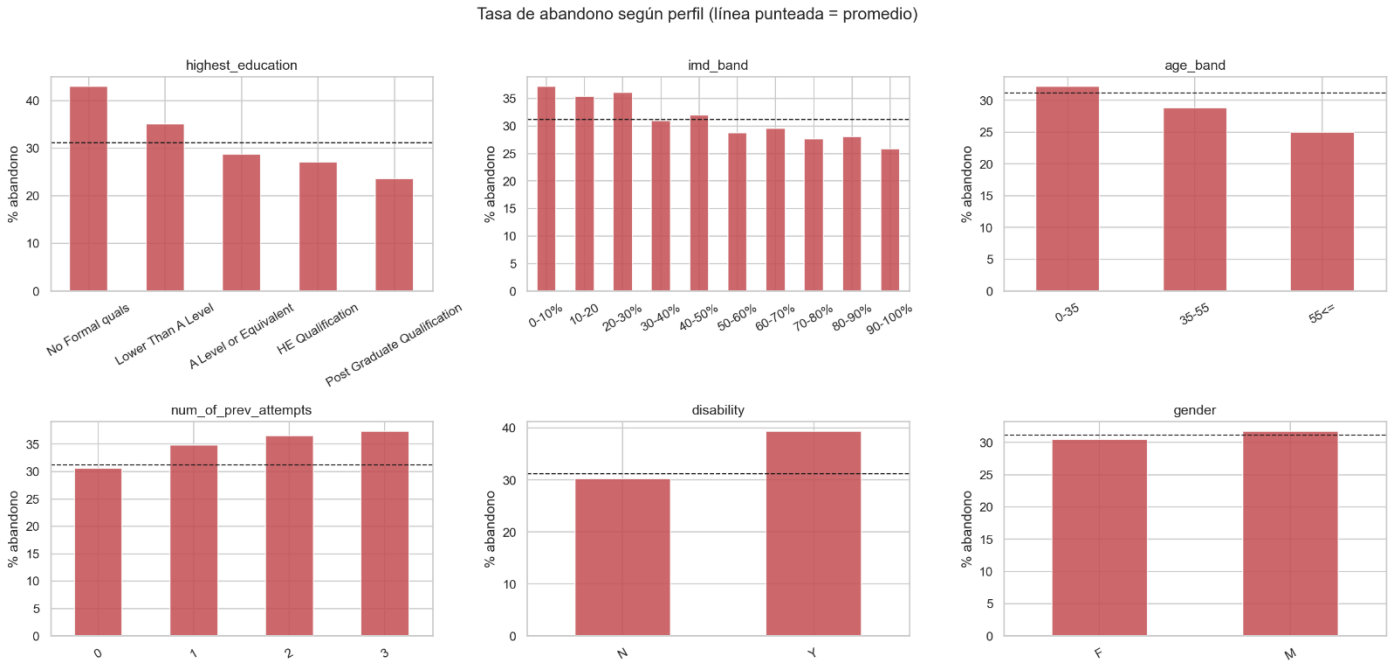
Conclusiones del análisis exploratorio







- La tasa de aprobación de materias es bastante baja de por sí, menos del 50%.
- El abandono varía mucho entre módulos: de 12% a 45%. Por eso el módulo debe incluirse como contexto.
- Quienes abandonan después del día 30 tienen aproximadamente 22% menos actividad en el primer mes: mediana de 193 contra 249 clics. Las distribuciones se superponen bastante, así que la señal existe, pero es moderada. El día 30 casi todos siguen activos: en ambos grupos, la mediana de días sin actividad es 1.
- El 27% de las bajas ocurre antes del inicio de la cursada, 24% entre el inicio de la cursada y el día 30, y 49% después del día 30.



- La tasa de abandono es mayor con menor nivel educativo previo, en barrios más desfavorecidos (lo que mide la banda IMD), entre quienes recursan y entre quienes declaran discapacidad.
- No parece existir una fuerte correlación entre la tasa de abandono y la edad o el género.

Preparación e ingeniería de variables

Se construyó una fila por inscripción activa al día 30: 27357 inscripciones, con 18,1% de abandono posterior. Se calcularon 41 variables solo con datos hasta ese día, para evitar fuga de información. Se agrupan en cuatro familias:

- **Perfil:** nivel educativo, edad, IMD, intentos previos, créditos que cursa en simultáneo, anticipación de la inscripción.
- **Contexto:** módulo, semestre, duración de la cursada.
- **Campus virtual:** volumen de clics, días activos, recencia, tendencia de las últimas dos semanas, clics por tipo de recurso y actividad relativa a la mediana de su propia cursada.
- **Evaluaciones:** entregas, evaluaciones vencidas no entregadas, días de atraso, nota media y ponderada.

El preprocesamiento es el mismo para todos los modelos: transformación logarítmica y estandarización de los conteos, imputación por mediana con indicador de faltante y one-hot encoding de las variables categóricas.

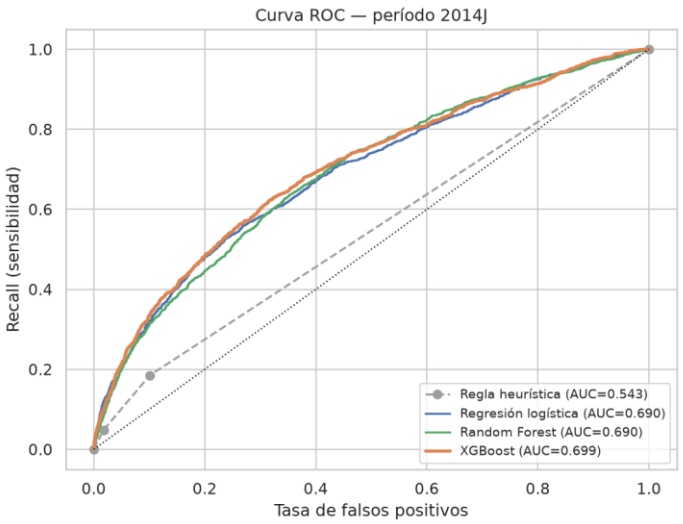
Metodología y esquema de validación

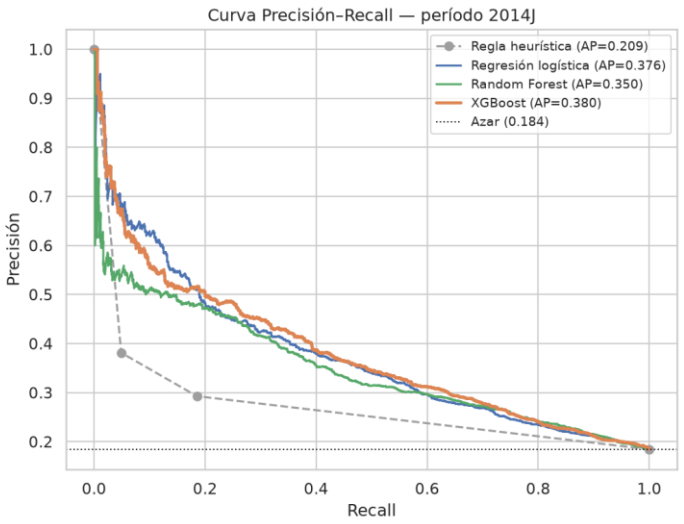
Se usó una validación cruzada agrupada por estudiante, para que la misma persona no apareciera en entrenamiento y validación. El período 2014J quedó como test: 9.111 inscripciones que el modelo no vio durante el entrenamiento. La métrica principal fue PR-AUC, y se fijó de antemano el criterio de selección: elegir el modelo con mejor PR-AUC en validación cruzada.

Modelado y evaluación

Algoritmos y métricas

Modelo	PR-AUC (CV)	PR-AUC test	ROC-AUC test	Recall @30%	Precision @30%	F1
Azar	—	0,184	0,500	30%	18%	—
Regla heurística	—	0,209	0,543	31%	19%	0,23
Regresión logística	0,370 ± 0,010	0,376	0,690	53%	33%	0,40
Random Forest	0,368 ± 0,004	0,350	0,690	51%	31%	0,39
XGBoost	0,375 ± 0,012	0,380	0,699	54%	33%	0,41





Selección del modelo

Se eligió XGBoost por el criterio que se había fijado de antemano: la mejor PR-AUC en validación cruzada. Ese resultado se confirmó en el test, con PR-AUC de 0,380 (IC 95%: 0,357–0,404) y ROC-AUC de 0,699 (IC 95%: 0,685–0,713). Si bien el valor es bajo, es el doble de lo obtenido con la regla heurística, que se establece como un valor de base que se obtiene estableciendo umbrales para la inactividad y entregas faltantes.

Si la alerta se genera más tarde, el modelo es más preciso. El ROC-AUC pasa de 0,69 el día 0, 0,70 el día 30 y 0,74 el día 120—, pero quedan menos estudiantes por salvar: 2.816, 1.680 y 739 en el estudiantado de testeo, respectivamente. Conviene alertar temprano y recalcular el riesgo semanalmente.

Explicación del riesgo

Para entender en qué se apoya el modelo se usó importancia por permutación: se mezclaron al azar los valores de una variable en los datos de testeo y se midió cuánto empeora la PR-AUC. Cuanto más cae, más depende el modelo de esa información. Como varias variables miden cosas parecidas —por ejemplo, las distintas formas de contar clics—, también se permutaron familias completas de variables.

Familia de variables	Variables	Caída de PR-AUC	% del total
Evaluaciones (entregas, notas, atrasos)	9	0,151	66%
Contexto del módulo	4	0,027	12%
Perfil académico (créditos, intentos, educación)	4	0,026	11%
Actividad en el campus virtual	19	0,015	6%
Perfil sociodemográfico (atributos sensibles)	5	0,011	5%

Las evaluaciones explican dos tercios de la capacidad predictiva: atraso medio, notas y evaluaciones vencidas sin entregar. Esto confirma H2. Le siguen el módulo y la carga de créditos simultáneos. Una vez que se conocen las evaluaciones, la actividad en el campus virtual aporta

poco (6%), así que H1 se confirma solo en parte. Dentro de esa familia, la variable más útil es la actividad relativa a la cursada. El perfil sociodemográfico aporta apenas el 5%, lo que confirma H3. Estas son asociaciones, no causas.

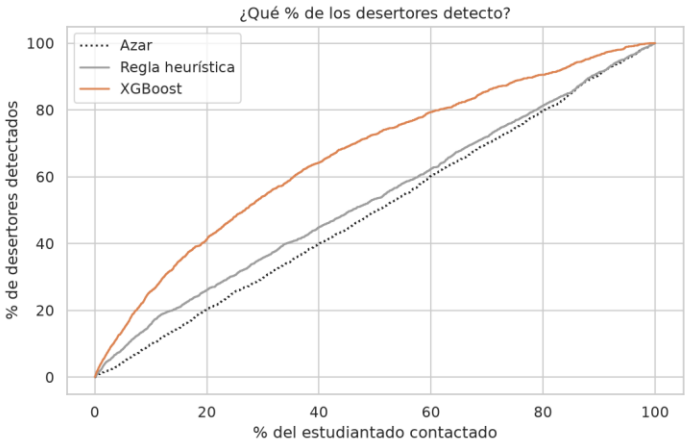
Grupo de riesgo	N	Abandono real	Nota media	Con entregas vencidas	Atraso (días)	Actividad relativa	Créditos
Muy alto (top 10%)	911	47% (2,6×)	45	35%	+30,5	0,89	90
Alto (10–30%)	1.822	26% (1,4×)	66,5	11%	0	0,73	60
Resto (70%)	6.378	12% (0,7×)	89	0%	–2	1,1	60

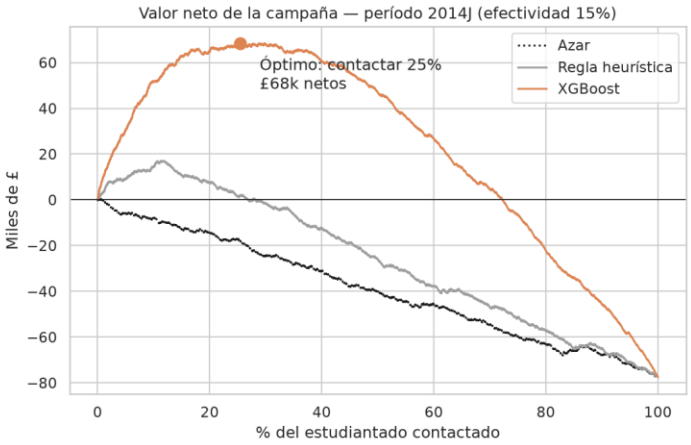
El 10% de mayor riesgo abandona 2,6 veces más que el promedio. Su nota media es de 45, entrega con 3 días de atraso, uno de cada tres tiene una evaluación vencida sin entregar y cursa 90 créditos a la vez.

Impacto en el negocio

Contactar a un estudiante conviene solo si su probabilidad de abandonar, multiplicada por la efectividad de la intervención y por el ingreso en juego, supera el costo del contacto. Se establecen valores de referencia basados en una búsqueda preliminar, pero no están validados con la institución.

Supuesto	Valor	Justificación
Ingreso por estudiante retenido	£ 1.500	Arancel aproximado de un módulo de 30–60 créditos
Costo por intervención	£ 50	honorario hora de un tutor más coordinación
Efectividad de la intervención	15%	Rango de 5% a 25% reportado en programas de alerta temprana





Capacidad de contacto	Azar	Regla heurística	XGBoost
10% (912 estudiantes)	168 detectados / –£7.800	268 / £14.700	432 / £51.600
20% (1.823 estudiantes)	342 / –£14.200	439 / £7.625	693 / £64.775
30% (2.734 estudiantes)	499 / –£24.425	600 / –£1.700	909 / £67.825

Lo óptimo sería contactar al 25% de mayor riesgo, con aprox. £68.500 netos por período y unos 120 estudiantes retenidos. Sensibilidad: con efectividad del 10%, el valor cae a aprox. £20.000 contactando al 13%; con 20%, sube aprox. £145.000 contactando al 44%. Contactar a todos solo es rentable con efectividad de 20% o más, y aun así queda por debajo del modelo.

Limitaciones

- 2 de cada 3 alertas son falsas alarmas. Por eso es importante que el costo de la intervención se mantenga bajo.
- Los datos son de 2013–2014. Además, la tasa de abandono varía entre períodos (de 15% a 20%), así que hay que monitorear el drift y reentrenar cada semestre.

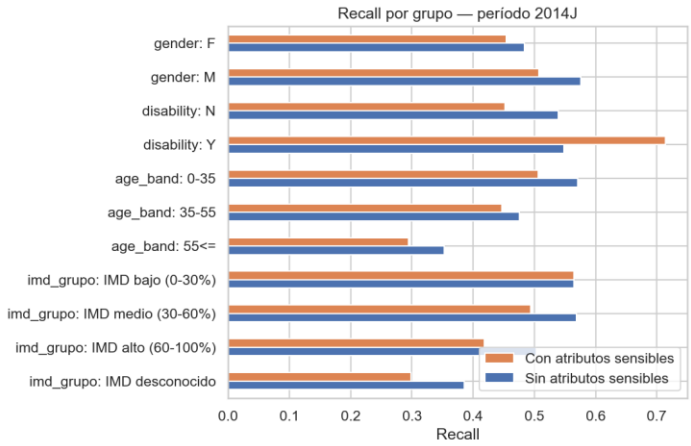
Consideraciones éticas y de privacidad

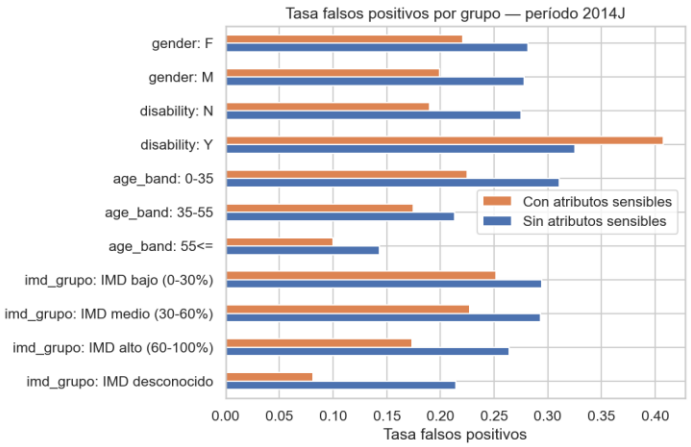
Los datos están anonimizados y se usan bajo licencia Creative Commons. Según los autores del dataset, los estudiantes fueron informados del uso con fines de investigación, pero la universidad no ofrece la opción de excluirse.

Equidad. Se midió, por grupo, qué proporción de quienes abandonan detecta el modelo (recall) y qué proporción de quienes no abandonan es alertada por error (tasa de falsos positivos, FPR):

Grupo	Abandono real	% alertados	Recall	FPR	FPR sin atrib. sensibles
Sin discapacidad	17,7%	23,7%	46%	18,9%	Brecha: 20 → 5 p.p.
Con discapacidad	25,9%	46,7%	68%	39,3%	—
IMD bajo (0–30%)	20,8%	31,9%	57%	25,2%	Brecha: 12 → 3 p.p.
IMD alto (60–100%)	16,7%	21,7%	42%	17,5%	—
Mujeres	17,2%	21,3%	42%	17,0%	Brecha: 6 → 8 p.p.
Hombres	19,3%	29,1%	53%	23,3%	—

Con todas las variables, el modelo alerta por error al 39% de los estudiantes con discapacidad que no iban a abandonar, contra el 19% del resto. Al excluir los atributos sensibles, la PR-AUC baja apenas 0,008 y las brechas por discapacidad y por nivel socioeconómico se reducen a menos de un tercio. Las brechas por género y edad se mantienen, posiblemente porque otras variables de comportamiento las reflejan indirectamente, y deberían monitorearse.





Conclusiones y recomendaciones

- Es posible anticipar el abandono al día 30 con un desempeño moderado pero útil: contactando al 30% del estudiantado se detecta a más de la mitad de los futuros desertores, lo que cumple el objetivo planteado (54% frente a la meta de 50%) y casi duplica lo que logra la regla actual.
- La señal más valiosa es el desempeño en las primeras evaluaciones: notas, atrasos y entregas faltantes explican dos tercios de la capacidad predictiva. Le siguen el módulo y la carga de créditos. El perfil sociodemográfico aporta apenas el 5%.
- Con algunos supuestos conservadores, el modelo reduce la pérdida de ingresos respecto de otras soluciones, como contactar a todo el alumnado, contactar a un número aleatorio de alumnos, o no hacer nada.
- Excluir los atributos sensibles tiene un impacto mínimo en la precisión. Incluirlos podría tener un impacto negativo en la percepción del alumnado porque el excesivo contacto con alumnos con bajo IMD o con discapacidad puede sentirse alienador o estigmatizante.